

РЕФЕРАТ

Теми: формати даних OLAP, використання сховища даних, вітрина даних, задачі Data Mining

Вступ

У сучасних інформаційних системах накопичується велика кількість операційних даних: транзакції, дії користувачів, продажі, бронювання, перегляди, прослуховування, події та технічні журнали. Для прийняття управлінських рішень недостатньо просто зберігати ці дані в робочій базі. Їх потрібно очищати, інтегрувати, агрегувати та аналізувати. Саме для цього використовуються OLAP-технології, сховища даних, вітрини даних і методи Data Mining.

1. Формати даних OLAP

OLAP (Online Analytical Processing) - це технологія багатовимірного аналізу даних, призначена для швидкого отримання аналітичних зрізів, підсумків і порівнянь. На відміну від OLTP-систем, які обслуговують поточні операції, OLAP орієнтований на аналіз історичних і агрегованих даних.

Основні поняття OLAP:

- Факт - числовий показник, який аналізується: кількість продажів, сума платежів, кількість прослуховувань, кількість бронювань.
- Вимір - ознака, за якою аналізуються факти: час, місто, користувач, жанр, подія, товар.
- Міра - конкретне значення факту: revenue, play_count, booking_count, average_rating.
- Куб даних - багатовимірна структура, у якій факти розглядаються через різні виміри.

Основні формати / підходи зберігання OLAP-даних:

Формат	Сутність	Переваги	Недоліки
MOLAP	Дані зберігаються у багатовимірних кубах.	Висока швидкість агрегованих запитів; зручність для бізнес-аналітики.	Може потребувати багато пам'яті; менш гнучкий для дуже детальних даних.
ROLAP	OLAP-аналіз виконується поверх реляційної БД.	Добре масштабується; використовує SQL; зручно для великих сховищ.	Запити можуть бути повільнішими, якщо немає правильних індексів та агрегатів.
HOLAP	Поєднання MOLAP і ROLAP.	Баланс швидкості та масштабованості.	Складніша архітектура та адміністрування.
Columnar / Parquet	Колонкове зберігання для аналітики та data lake.	Ефективне стиснення; швидке читання потрібних колонок.	Потребує окремих інструментів обробки та керування файлами.

На практиці OLAP-дані часто моделюються за схемою «зірка» або «сніжинка». У центрі знаходиться таблиця фактів, а навколо неї - таблиці вимірів. Наприклад, для музичної платформи фактом може бути прослуховування треку, а вимірами - час, DJ, жанр, країна та тип користувача.

2. Використання сховища даних

Сховище даних (Data Warehouse) - це централізована база, призначена для зберігання інтегрованих, очищених, історичних і структурованих даних з різних джерел. Основна мета сховища даних - підтримка аналітики, звітності та прийняття управлінських рішень.

Класичні властивості сховища даних:

- Предметна орієнтованість - дані організовані навколо бізнес-напрямів: продажі, користувачі, бронювання, музика, події.
- Інтегрованість - дані з різних систем приводяться до спільних форматів, довідників і правил.
- Незмінність - після завантаження історичні дані зазвичай не редагуються, а доповнюються новими записами.

- Прив'язка до часу - зберігається історія змін і подій, що дозволяє аналізувати динаміку.

Типова архітектура включає джерела даних, staging area, ETL/ELT-процеси, центральне сховище, вітрини даних і BI/OLAP-інструменти. ETL означає Extract, Transform, Load: дані витягуються з джерел, очищаються, трансформуються і завантажуються в сховище. ELT відрізняється тим, що трансформації виконуються вже всередині сховища або хмарної аналітичної платформи.

Приклади використання сховища даних:

- аналіз продажів, доходів і фінансових показників;
- оцінка ефективності маркетингових кампаній;
- аналіз поведінки користувачів у цифрових продуктах;
- контроль якості бізнес-процесів;
- прогнозування попиту та навантаження;
- побудова управлінських dashboard-звітів.

3. Вітрина даних

Вітрина даних (Data Mart) - це тематично обмежена частина сховища даних, яка створюється для конкретного підрозділу, ролі або аналітичної задачі. Якщо сховище даних охоплює всю організацію, то вітрина концентрується на окремому напрямі: фінансах, маркетингу, продажах, користувацькій активності або продуктивності сервісу.

Типи вітрин даних:

- Залежна вітрина - формується з центрального сховища даних. Це найбільш контрольований і узгоджений варіант.
- Незалежна вітрина - створюється напряму з джерел даних для швидкого вирішення локальної задачі.
- Гібридна вітрина - поєднує дані зі сховища та окремих операційних систем.

Наприклад, у системі на кшталт ROOM_9 можна створити окремі вітрини: «Аналітика DJ», «Бронювання», «Прослуховування треків», «Події та стріми». Вітрина «Аналітика DJ» може містити кількість переглядів профілю, кількість прослуховувань, популярні треки, кількість заявок і коефіцієнт прийнятих бронювань.

Критерій	Сховище даних	Вітрина даних
Масштаб	Охоплює всю організацію або всю систему.	Охоплює один напрям або групу задач.
Користувачі	Аналітики, менеджмент, BI-команди.	Конкретний відділ або роль.
Складність	Більш складна модель та інтеграція.	Простіша структура, швидший доступ.
Приклад	Усі дані платформи: користувачі, платежі, події, музика.	Тільки dashboard для DJ або тільки фінансова аналітика.

4. Задачі Data Mining

Data Mining - це процес виявлення прихованих закономірностей, залежностей і корисних знань у великих масивах даних. На відміну від звичайної звітності, Data Mining не тільки відповідає на питання «що сталося?», а й допомагає зрозуміти «чому це сталося?» та «що може статися далі?».

Задача	Сутність	Приклад
Класифікація	Віднесення об'єкта до одного з наперед відомих класів.	Визначити, чи буде заявка на бронювання прийнята або відхилена.
Кластеризація	Групкування об'єктів без наперед заданих класів.	Знайти групи слухачів зі схожими музичними вподобаннями.
Регресія	Прогнозування числового значення.	Спрогнозувати кількість прослуховувань треку або очікуваний дохід.
Асоціативні правила	Пошук правил виду «якщо А, то часто В».	Користувачі, які слухають techno, часто зберігають industrial DJ.

Задача	Сутність	Приклад
Виявлення аномалій	Пошук нетипових або підозрілих записів.	Виявити різкий штучний сплеск прослуховувань або підозрілу платіжну активність.
Прогнозування часових рядів	Передбачення майбутніх значень за історичною динамікою.	Прогноз активності подій, сезонності бронювань або навантаження на платформу.

У бізнесі Data Mining застосовується для персоналізації рекомендацій, сегментації клієнтів, прогнозування попиту, виявлення шахрайства, оптимізації цін і підтримки стратегічних рішень. У цифрових музичних сервісах ці методи особливо важливі для рекомендацій треків, підбору артистів, аналізу аудиторії та планування подій.

Висновок

OLAP, сховище даних, вітрини даних і Data Mining є взаємопов'язаними елементами сучасної аналітичної інфраструктури. OLAP забезпечує швидкий багатовимірний аналіз, сховище даних створює надійну історичну основу, вітрини даних надають зручні тематичні зрізи, а Data Mining дозволяє знаходити приховані закономірності та будувати прогнози. Разом ці підходи перетворюють накопичені дані на практичні знання для управління системою, бізнесом або цифровою платформою.